TRƯỜNG ĐẠI HỌC CÔNG NGHIỆP HÀ NỘI
KHOA CÔNG NGHỆ THÔNG TIN
=====***=====



BÁO CÁO BÀI TẬP LỚN HỌC PHẦN:
ANH NINH MẠNG

ĐỀ TÀI: PHÁT HIỆN XÂM NHẬP MẠNG SỬ DỤNG KỸ THUẬT HỌC MÁY VÀ DEMO

Giảng viên: TS. Lê Thị Anh
Nhóm - Lớp: 11 - 20232IT6070001
Thành viên:

Phan Trịnh Nam Thái	2021602624
Phan Văn Thức	2021603496
Phạm Quốc Tiến	2021608451
Đào Duy Toàn	2021604926
Nguyễn Chí Tôn	2021608868

Hà Nội, Năm 2024

LỜI CẢM ƠN

Để hoàn thành tốt bài báo cáo thí nghiệm/ thực nghiệm này, chúng em xin gửi lời cảm ơn sâu sắc đối với cô Lê Thị Anh - người đã định hướng lối đi cho nhóm để hoàn thiện đề tài của mình. Những kiến thức trong quá trình học không chỉ là nền tảng cho quá trình làm đề tài mà còn là hành trang quý báu giúp nhóm có thể tiếp tục học tập và làm việc sau này. Trong quá trình thực hiện đề tài, nhóm đã rất cố gắng hoàn thiện công việc được giao. Tuy nhiên với vốn kiến thức còn hạn chế nên đề tài của nhóm còn gặp nhiều thiếu sót. Rất mong nhận được sự đóng góp quý báu từ phía cô để đề tài của nhóm có thể hoàn thiện hơn. Một lần nữa, nhóm xin cảm ơn và kính chúc cô sức khỏe, thành công trong sự nghiệp.

Chúng em xin chân thành cảm ơn!

MỤC LỤC

LỜI CẢM ƠN 2
MỤC LỤC 3
DANH MỤC TỪ VIẾT TẮT 5
DANH MỤC HÌNH ẢNH 6
DANH MỤC BẢNG BIỂU 6
MỞ ĐẦU 7
1.1. Tính cấp thiết của đề tài 7
1.2. Mục đích nghiên cứu 7
1.3. Đối tượng nghiên cứu 8
1.4. Nhiệm vụ nghiên cứu 8
1.5. Giới hạn và phạm vi nghiên cứu 8
1.6. Phương pháp nghiên cứu 8
1.7. Bố cục 8
CHƯƠNG 1. CƠ SỞ LÝ THUYẾT 9
1.1. Các kỹ thuật học máy để phát hiện xâm nhập mạng 9
1.1.1. Các loại xâm nhập mạng (Types of Network Intrusions) 9
1.1.2. Phương pháp phát hiện xâm nhập (Intrusion Detection Methods) 10
1.1.3. Học máy trong Phát hiện Xâm nhập (Machine Learning for Intrusion Detection) 10
1.2. Các kỹ thuật học máy để phát hiện xâm nhập mạng 11
1.2.1. Kỹ thuật học có giám sát 11
1.2.2. Kỹ thuật học nửa giám sát 12
1.2.3. Kỹ thuật học không giám sát 12
CHƯƠNG 2. CÁC MÔ HÌNH 13
2.1. Mô hình phát hiện xâm nhập mạng trái phép 13
2.1.1. Cây quyết định (Decision Tree) 13
2.1.2. Percerptron nhiều lớp (Multilayer Perceptron Classifier) 14
2.1.3. Hồi quy Logistic (Logistic Regression) 14

2.1.4. Mô hình rừng cây (Random Forest Regression) 15
2.1.5. Huấn luyện và đánh giá mô hình.....15
2.2. Các bộ dữ liệu.....16
2.2.1. Bộ dữ liệu KDD cup 1999.....16
2.2.2. Bộ dữ liệu NSL-KDD.....19
CHƯƠNG 3. KẾT QUẢ ĐẠT ĐƯỢC.....21
3.1. Xây dựng chương trình.....21
3.2. Kết quả thực nghiệm 22
3.2.1. Đánh giá hoạt động của các mô hình 22
3.2.2. So sánh kết quả với bộ dữ liệu với các model khác nhau 25
3.2.3. Kết luận 27
3.2.4. Hướng phát triển.....28
TÀI LIỆU THAM KHẢO 29

DANH MỤC TỪ VIẾT TẮT

STT	Ký hiệu chữ viết tắt	Chữ viết đầy đủ	Dịch nghĩa
1	DDos	Distributed Denial of Service	Tấn công từ chối dịch vụ phân tán
2	DoS	Denial of Service	Tấn công từ chối dịch vụ
3	APT	Advanced Persistent Threats	Các mối đe dọa nâng cao
4	NIDS	Network Intrusion Detection System	Hệ thống phát hiện xâm nhập mạng
5	HIDS	Host-based Intrusion Detection System	Hệ thống phát hiện xâm nhập dựa trên máy chủ
6	IPS	Intrusion Prevention System	Hệ thống ngăn chặn xâm nhập
7	SVM	Support Vector Machines	
8	PCA	Principal Component Analysis	Phân tích thành phần chính
9	RNN	Recurrent Neural Networks	Mạng thần kinh hồi quy
10	MLP	Multilayer Perceptron	Perceptron đa lớp

DANH MỤC HÌNH ẢNH

Hình 1.1. Mô hình học có giám sát. 12
Hình 2.1. Decision Tree....13
Hình 3.1. Giao diện trang web kaggle....21
Hình 3.2. Tạo bản sao chương trình 21
Hình 3.3. Hai bộ dữ liệu KDD Cup 1999 và NSL-KDD đã được tải lên sẵn 22
Hình 3.4. Kiểm tra đường dẫn đến bộ dữ liệu....22
Hình 3.5. Chạy chương trình với bộ dữ liệu đã chọn....22
Hình 3.6. Kết quả các mô hình khi chạy với bộ dữ liệu KDD Cup 1999 26
Hình 3.7. Kết quả các mô hình khi chạy với bộ dữ liệu NSL-KDD 26

DANH MỤC BẢNG BIỂU

Bảng 2.1. Các dạng tấn công chính trong bộ dữ liệu KDD cup 1999....16
Bảng 2.2. Các tính năng cơ bản của từng kết nối TCP 17
Bảng 2.3. Các tính năng nội dung trong kết nối được đề xuất bởi kiến thức miền....17
Bảng 2.4. Các đặc điểm giao thức được tính toán bằng cửa sổ thời gian hai giây 18
Bảng 2.5. Các dạng tấn công chính trong bộ dữ liệu NSL-KDD....20
Bảng 3.1. Kết quả chạy mô hình Decision Tree Classifier 23
Bảng 3.2. Kết quả chạy mô hình Multilayer Perceptron Classifier 24
Bảng 3.3. Kết quả chạy mô hình Logistic Regression 24
Bảng 3.4. Kết quả chạy mô hình Random Forest Regression....24
Bảng 3.5. So sánh kết quả các mô hình....25

MỞ ĐẦU

1.1. Tính cấp thiết của đề tài

Trong thời đại số ngày nay, an ninh mạng không chỉ là một vấn đề quan trọng mà còn là một yêu cầu bắt buộc. Đối diện với sự gia tăng của các cuộc tấn công xâm nhập mạng và sự phức tạp của chúng, việc sử dụng Machine Learning để phát hiện xâm nhập trở thành một phương pháp hiệu quả để bảo vệ hệ thống và dữ liệu quan trọng.

Trong thời gian gần đây, sự phát triển của Machine Learning đã mang lại những tiến bộ đáng kể trong nhiều lĩnh vực, từ công nghệ, y tế, tài chính đến an ninh mạng. Sử dụng Machine Learning để phát hiện xâm nhập mạng bằng cách học từ dữ liệu lịch sử về các mẫu tấn công và dự đoán các hành vi không mong muốn trong tương lai đã giúp hệ thống phản ứng nhanh chóng và hiệu quả hơn đối với các mối đe dọa mạng.

Mô hình của nhóm sử dụng các bộ dữ liệu có sẵn giúp tiết kiệm thời gian và tài nguyên để thực hiện nghiên cứu. Các bộ dữ liệu như KDD Cup 1999 và NSL – KDD cung cấp dữ liệu đa dạng về các biểu hiện của xâm nhập mạng. Kết quả của dự án có thể được áp dụng trong thực tế để cải thiện bảo mật hệ thống mạng và giảm nguy cơ xâm nhập mạng.

Lợi thế của Machine Learning là khả năng học từ dữ liệu và phát hiện các biểu hiện tấn công mà không cần biết trước chữ ký cụ thể. Điều này khiến nó trở thành một công cụ mạnh mẽ cho việc phát hiện xâm nhập mạng. Phương pháp sử dụng Machine Learning giúp tự động hóa quá trình phát hiện, giảm thiểu sự can thiệp của con người và thời gian phản ứng đối với các cuộc tấn công. Các mô hình Machine Learning có thể được điều chỉnh cho các môi trường và loại tấn công cụ thể, từ đó tăng độ chính xác và tin cậy trong việc phát hiện xâm nhập mạng.

Tóm lại, sự phát triển của Machine Learning đã đem lại những tiềm năng lớn trong việc nâng cao khả năng bảo vệ an ninh mạng. Sử dụng công nghệ này có thể giúp tổ chức và các nhà nghiên cứu ngăn chặn hiệu quả các mối đe dọa mạng và bảo vệ thông tin quan trọng.

1.2. Mục đích nghiên cứu

Mục đích của đề tài là tìm hiểu cách triển khai và xây dựng một hệ thống đồng thời đánh giá tính khả thi của nó. Nhận định ưu điểm và nhược điểm của một mô hình phát hiện xâm nhập mạng từ đó tìm và đưa ra giải pháp đối với hạn chế của quy trình hoạt động.

1.3. Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài này là mô hình phát hiện xâm nhập mạng thông qua thuật toán học máy.

1.4. Nhiệm vụ nghiên cứu

Nhiệm vụ nghiên cứu của đề tài: Khảo sát, nghiên cứu, tìm hiểu các chức năng, quy trình hoạt động, cơ sở dữ liệu, ... của một hệ thống phát hiện xâm nhập mạng.

1.5. Giới hạn và phạm vi nghiên cứu

Phạm vi nằm trong giới hạn học phần An ninh mạng và các mục tiêu phục vụ hệ thống thư viện số của trường Đại học Công nghiệp Hà Nội.

1.6. Phương pháp nghiên cứu

Sử dụng một số phương pháp: Nghiên cứu thực tế, chạy thử dữ liệu bằng thuật toán AI Machine Learning để đưa ra tỉ lệ phát hiện chính xác xâm nhập mạng.

- Phương pháp nghiên cứu tài liệu
- Nghiên cứu về xử lý thông tin định tính
- Nghiên cứu về xử lý thông tin định lượng.

1.7. Bố cục

Nội dung đề tài được chia thành 3 chương:

Chương 1: Cơ sở lý thuyết

Chương 2: Các mô hình

Chương 3: Kết quả đạt được

CHƯƠNG 1. CƠ SỞ LÝ THUYẾT

1.1. Các kỹ thuật học máy để phát hiện xâm nhập mạng

Xâm nhập mạng (Network Intrusion) là việc không được phép truy cập, can thiệp hoặc tấn công vào mạng máy tính hoặc hệ thống thông tin mà không có sự cho phép của chủ sở hữu. Điều này có thể dẫn đến mất mát thông tin quan trọng hoặc việc hỏng hóc hệ thống.

Mục tiêu của Xâm nhập mạng: Xâm nhập mạng có thể có các mục tiêu như đánh cắp dữ liệu, gây thất thoát dịch vụ, truy cập trái phép vào hệ thống, hoặc thậm chí là phá hủy dữ liệu.

1.1.1. Các loại xâm nhập mạng (Types of Network Intrusions)

Xâm nhập từ xa (Remote Intrusion): Khi một kẻ tấn công từ xa cố gắng xâm nhập vào hệ thống thông qua mạng, thường bằng cách sử dụng các lỗ hổng bảo mật hoặc tấn công từ chối dịch vụ (DDoS).

Xâm nhập từ bên trong (Internal Intrusion): Khi một người dùng hoặc nhân viên nội bộ cố gắng xâm nhập hoặc thực hiện các hoạt động xâm nhập từ bên trong hệ thống.

Tấn công từ chối dịch vụ (Denial of Service - DoS): Tấn công này nhằm làm cho dịch vụ mạng trở nên không khả dụng bằng cách làm ngập hệ thống với lưu lượng truy cập quá mức, làm cạn kiệt tài nguyên hệ thống.

Tấn công từ chối dịch vụ phân tán (Distributed Denial of Service - DDoS): Tương tự như DoS, nhưng tấn công DDoS sử dụng nhiều máy tính bị nhiễm phần mềm độc hại để thực hiện tấn công đồng thời từ nhiều nguồn.

Xâm nhập qua lỗ hổng bảo mật (Exploiting Security Vulnerabilities): Kẻ tấn công khai thác các lỗ hổng trong phần mềm hoặc hệ điều hành để xâm nhập vào hệ thống. Ví dụ: SQL Injection, Buffer Overflow, Cross-Site Scripting (XSS).

Phishing: Kẻ tấn công gửi email hoặc tin nhắn giả mạo để lừa người dùng cung cấp thông tin cá nhân như mật khẩu, số thẻ tín dụng.

Malware (Malicious Software): ao gồm virus, sâu (worms), trojan horse, spyware, ransomware, v.v. Malware có thể được sử dụng để xâm nhập và kiểm soát hệ thống, đánh cắp thông tin, hoặc gây hại cho dữ liệu.

Man-in-the-Middle (MitM) Attack: Kẻ tấn công chặn và có thể thay đổi thông tin liên lạc giữa hai bên mà họ không hề hay biết. Ví dụ: eavesdropping, session hijacking.

Password Attacks: Tấn công mật khẩu như brute force, dictionary attacks, và credential stuffing để đoán hoặc đánh cắp mật khẩu.

Advanced Persistent Threats (APT): Tấn công APT thường do các tổ chức tinh vi thực hiện, nhằm xâm nhập và duy trì truy cập vào mạng trong thời gian dài mà không bị phát hiện để đánh cắp dữ liệu nhạy cảm.

Insider Threats: Xâm nhập từ bên trong, có thể do nhân viên hoặc người dùng nội bộ hệ thống thực hiện. Họ lợi dụng quyền truy cập hợp pháp để thực hiện các hành vi trái phép.

Rogue Access Points: Thiết lập các điểm truy cập Wi-Fi giả mạo để đánh lừa người dùng kết nối và sau đó đánh cắp thông tin.

Drive-By Downloads: Tấn công mà kẻ tấn công cài đặt phần mềm độc hại trên thiết bị của người dùng mà họ không hề hay biết, thường qua việc truy cập vào các trang web bị nhiễm.

1.1.2. Phương pháp phát hiện xâm nhập (Intrusion Detection Methods)

Dựa vào chữ ký (Signature-based Detection): Phương pháp này dựa trên việc so sánh các dấu vết của tấn công với các mẫu đã biết trước (chữ ký). Nếu một dấu vết tương tự được tìm thấy, hệ thống cảnh báo về một tấn công.

Phát hiện dựa trên hành vi (Anomaly-based Detection): Phương pháp này phát hiện các hoạt động bất thường bằng cách xây dựng mô hình hành vi bình thường và cảnh báo nếu có sự sai khác đáng kể.

Hệ thống phát hiện xâm nhập mạng (Network Intrusion Detection System - NIDS): NIDS giám sát và phân tích lưu lượng mạng đến và đi qua hệ thống để phát hiện các dấu hiệu xâm nhập. NIDS thường được đặt tại các điểm quan trọng trong mạng như bộ định tuyến hoặc tường lửa.

Hệ thống phát hiện xâm nhập máy chủ (Host-based Intrusion Detection System - HIDS): HIDS giám sát và phân tích các hoạt động trên một máy chủ cụ thể để phát hiện các hành vi bất thường hoặc trái phép. HIDS kiểm tra các tệp log, tệp hệ thống, và các quá trình đang chạy.

Phát hiện dựa trên phân tích giao thức (Protocol-based Detection): Phương pháp này phân tích các giao thức mạng để phát hiện các hoạt động bất thường hoặc không hợp lệ mà có thể là dấu hiệu của tấn công.

Hệ thống phòng chống xâm nhập (Intrusion Prevention System - IPS): Khác với hệ thống phát hiện xâm nhập (IDS), hệ thống phòng chống xâm nhập (IPS) không chỉ phát hiện mà còn có khả năng ngăn chặn và phản ứng lại các hành vi xâm nhập.

1.1.3. Học máy trong Phát hiện Xâm nhập (Machine Learning for Intrusion Detection)

Học máy được sử dụng để phát hiện xâm nhập mạng bằng cách phân tích lưu lượng mạng và nhận diện các mẫu bất thường. Các thuật toán học máy có thể học từ dữ liệu quá khứ để dự đoán và phát hiện các hoạt động xâm nhập mới. Nhờ khả năng tự động cải thiện và xử lý lượng lớn dữ liệu, học máy giúp nâng cao hiệu quả và độ chính xác trong việc phát hiện các mối đe dọa mạng.

Các thuật toán phổ biến bao gồm: Support Vector Machines (SVM), Random Forest, Neural Networks, và các mô hình phát hiện bất thường như Isolation Forest và One-Class SVM.

Học máy trong phát hiện xâm nhập còn tận dụng các thuật toán như K-Means Clustering để phát hiện các cụm bất thường, và Principal Component Analysis (PCA) để giảm chiều dữ liệu, giúp phát hiện các điểm dữ liệu không bình thường. Các kỹ thuật học sâu như Deep Neural Networks và Recurrent Neural Networks (RNN) cũng được sử dụng để xử lý các mẫu phức tạp và thời gian thực trong dữ liệu mạng.

Các bước triển khai bao gồm thu thập và tiền xử lý dữ liệu, trích xuất đặc trưng, huấn luyện mô hình, và đánh giá hiệu suất. Để đối phó với dữ liệu không cân đối, các kỹ thuật như SMOTE và class weighting được áp dụng. Cuối cùng, mô hình được triển khai và giám sát liên tục để đảm bảo hiệu suất phát hiện xâm nhập luôn được tối ưu hóa.

Một thách thức quan trọng trong việc áp dụng học máy vào phát hiện xâm nhập là đảm bảo tính chính xác và khả năng phát hiện trong thời gian thực. Điều này đòi hỏi việc tối ưu hóa mô hình để giảm độ trễ và tăng hiệu suất. Các mô hình cần được cập nhật thường xuyên với dữ liệu mới để duy trì hiệu quả phát hiện khi các mối đe dọa mạng ngày càng trở nên tinh vi.

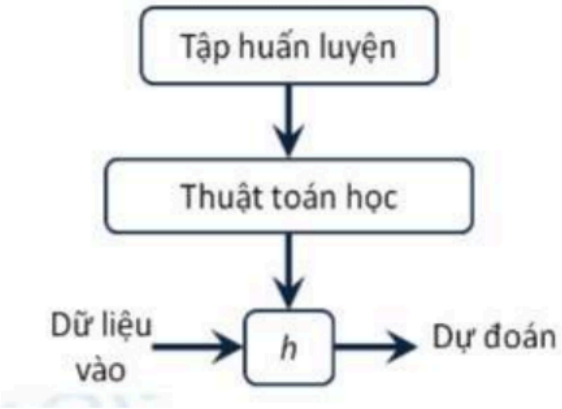
Ngoài ra, việc kết hợp các mô hình học máy với các phương pháp truyền thống như hệ thống phát hiện xâm nhập dựa trên chữ ký và quy tắc có thể tăng cường khả năng phát hiện toàn diện. Kết quả là, các hệ thống phát hiện xâm nhập được trang bị học máy không chỉ phát hiện nhanh chóng và chính xác các mối đe dọa mới mà còn thích nghi linh hoạt với các thay đổi trong môi trường mạng.

1.2. Các kỹ thuật học máy để phát hiện xâm nhập mạng

Phát hiện xâm nhập mạng sử dụng kỹ thuật học máy là một phương pháp hiệu quả để bảo vệ hệ thống mạng khỏi các cuộc tấn công. Các kỹ thuật học máy được sử dụng có thể chia thành ba loại chính: học có giám sát, học nửa giám sát, và học không giám sát.

1.2.1. Kỹ thuật học có giám sát

Học có giám sát (Supervised learning) là quá trình học với tập dữ liệu huấn luyện ban đầu hoàn toàn được gán nhãn từ trước. Học có giám sát sử dụng cho lớp bài toán phân lớp và phân loại. Với cách học này, kinh nghiệm được cho một cách tường minh dưới dạng đầu vào và đầu ra của hàm đích.



Hình 1.1. Mô hình học có giám sát.

Một số kỹ thuật học có giám sát thường được quan tâm là máy hỗ trợ vector, cây quyết định, mạng thần kinh nhân tạo, lập trình di truyền ...

1.2.2. Kỹ thuật học nửa giám sát

Kỹ thuật học nửa giám sát là kỹ thuật học sử dụng cả dữ liệu đã gán nhãn và chưa gán nhãn để huấn luyện - điển hình là một lượng nhỏ dữ liệu có gán nhãn cùng với lượng lớn dữ liệu chưa gán nhãn. Nhiều nhà nghiên cứu nhận thấy dữ liệu không gán nhãn, khi được sử dụng kết hợp với một lượng nhỏ dữ liệu có gán nhãn, có thể cải thiện đáng kể độ chính xác. Trong kỹ thuật học có giám sát, để gán nhãn dữ liệu cho bài toán học máy thường đòi hỏi một chuyên viên có kỹ năng để phân loại bằng tay các mẫu huấn luyện. Trong khi đó,chi phí gán nhãn bằng tay cao, không khả thi. Với phương pháp kết hợp cả mẫu dữ liệu được gán nhãn và chưa gán nhãn sẽ đạt được hiệu quả cao hơn.

1.2.3. Kỹ thuật học không giám sát

Trong kỹ thuật học không giám sát, tập dữ liệu được cho dưới dạng D={(x1,x1,...,xn)} với (x1,x1,...,xn) vector đặc trưng của mẫu huấn luyện. Nhiệm vụ của thuật toán là phải phân chia tập dữ liệu D thành các nhóm con, mỗi nhóm chứa các vector đầu vào có đặc trưng giống nhau. Như vậy, việc học không giám sát, số lớp phân loại chưa biết trước, và tùy theo tiêu chuẩn đánh giá độ tương tự giữa các mẫu mà ta có thể có các lớp phân loại khác nhau.

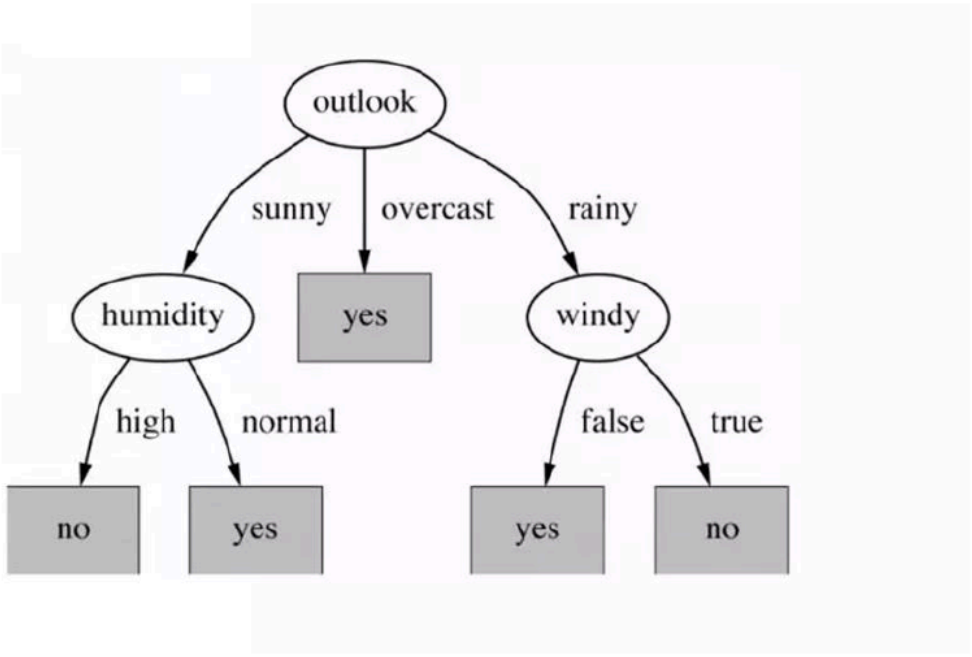
CHƯƠNG 2. CÁC MÔ HÌNH

2.1. Mô hình phát hiện xâm nhập mạng trái phép

2.1.1. Cây quyết định (Decision Tree)

Trong lĩnh vực An ninh mạng và phát hiện xâm nhập, mô hình cây quyết định là một công cụ mạnh mẽ và phổ biến để phân loại các hoạt động mạng và xác định xâm nhập. Decision Tree là một cấu trúc cây quyết định, mà mỗi nút của cây biểu diễn một quyết định dựa trên một tập hợp các luật và thuộc tính dữ liệu. mô hình cây quyết định có khả năng học từ dữ liệu và tạo ra các quyết định dựa trên các thuộc tính quan sát được. Trong dự án phát hiện truy cập trái phép, mô hình cây quyết định có thể được sử dụng để phân loại các sự kiện mạng thành các loại như "bình thường" hoặc "xâm nhập."

Một cây quyết định là một mô hình logic được biểu diễn như một cây, cho biết giá trị của một biến mục tiêu có thể được dự đoán bằng cách 20 dùng các giá trị của một tập các biến dự đoán [1,2,3,4]. Một số ưu điểm của cây quyết định như: xây dựng tương đối nhanh; đơn giản, dễ hiểu. Việc phân lớp dựa trên cây quyết định đạt được sự tương tự và đôi khi là chính xác hơn so với các phương pháp phân lớp khác.



Hình 2.1. Decision Tree

Trong đó:

Gốc: Nút trên cùng của cây.

Nút trong: Biểu diễn một kiểm tra trên một thuộc tính đơn.

Nhánh: Biểu diễn các kết quả của kiểm tra trên nút trong.

Nút lá: Biểu diễn lớp hay sự phân lớp.

Để phân lớp mẫu dữ liệu chưa biết, giá trị các thuộc tính của mẫu được đưa vào kiểm tra trên cây quyết định. Mỗi mẫu tương ứng có một đường đi từ gốc đến lá và lá biểu diễn dự đoán giá trị phân lớp mẫu đó. Cây quyết định được sử dụng để xây dựng một kế hoạch nhằm đạt được mục tiêu mong muốn. Các cây quyết định được dùng để hỗ trợ quá trình ra quyết định. Cây quyết định là một dạng đặc biệt của cấu trúc cây.

2.1.2. Percerptron nhiều lớp (Multilayer Perceptron Classifier)

Multilayer Perceptron (Perceptron nhiều lớp) là một thuật toán học máy có giám sát (Machine Learning) thuộc lớp Mạng nơ-ron nhân tạo, là tập hợp của các lớp khác nhau: Lớp đầu vào, lớp ẩn, lớp đầu ra. Đây là một trong những mô hình học sâu cơ bản và phổ biến nhất được sử rộng rãi trong các bài toán học có giám sát.

Multilayer Perceptron (MLP) có thể được sử dụng hiệu quả trong các bài toán an ninh mạng nhờ khả năng học và phát hiện các mẫu phức tạp trong dữ liệu mạng. Một số ứng dụng của mô hình MLP trong an ninh mạng như: Phát hiện xâm nhập mạng, phát hiện mã độc, phát hiện email lừa đảo.

Giải thích các tham số:

Solver: là tham số xác định thuật toán tối ưu hóa được sử dụng. Trong trường hợp này “adam” là một thuật toán tối ưu hóa được sử dụng.

Alpha: là tham số điều chỉnh của thuật toán. Alpha=1e-5 cho thấy sự điều chỉnh nhẹ nhàng, giúp mô hình không bị quá phức tạp và đồng thời không làm giảm quá nhiều độ chính xác của mô hình.

Hidden_layer_sizes: Phần tử thứ i đại diện cho số lượng nơ-ron trong lớp ẩn thứ i. Ở đây phần tử 300 đại diện cho số lượng nơ-ron trong lớp ẩn duy nhất của mạng nơ-ron.

Random_state: đảm bảo rằng kết quả của việc khởi tạo trọng số và phân chia dữ liệu sẽ nhất quán khi chạy lại mô hình. Ở đây giá trị 1 là một hạt giốngcụ thể và có thể thay đổi giá trị này để kiểm tra sự ổn định của mô hình.

2.1.3. Hồi quy Logistic (Logistic Regression)

Hồi quy logistic là một kỹ thuật thống kê và học máy sử dụng để mô hình hóa và phân tích mối quan hệ giữa một biến phụ thuộc nhị phân (binary dependent variable) và một hoặc nhiều biến độc lập (independent variables). Kỹ thuật này đặc biệt hữu ích trong các bài toán phân loại và dự đoán sự kiện bảo mật như phát hiện xâm nhập, phát hiện mã độc.

Giải thích các tham số:

Max_iter: Số lượng vòng lặp tối đa mà thuật toán tối ưu sẽ chạy. Giá trị mặc định trong hàm LogisticRegression = 100. Nhưng để tăng hiệu suất của mô hình, nhóm thay đổi số vòng lặp lên 150

Random_state: Tham số giúp đảmbảo trình tạo số ngẫu nhiên tạo ra cùng một chuỗi các số ngẫu nhiên mỗi khi được cung cấp cùng 1 random state. Giá trị thường dùng là 42.

2.1.4. Mô hình rừng cây (Random Forest Regression)

Cây quyết định là một mô hình khá nổi tiếng hoạt động trên cả bài toán phân loại và dự báo của học có giám sát. Tuy vậy, mô hình này tồn tại một vài hạn chế khá lớn khi dễ dàng xảy ra hiện tượng overfiting hay chỉ tạo ra một kịch bản dự báo duy nhất cho mỗi một quan sát. Vì vậy, mô hình rừng cây (Random Forest Regression) được ra đời nhằm cải tiến mô hình tiền nhiệm.

Mô hình Random Forest Regression được huấn luyện dựa trên sự phối hợp giữa luật kết hợp (ensembling) và quá trình lấy mẫu tái lặp (bootstrapping). Cụ thể thuật toán này tạo ra nhiều cây quyết định và mỗi cây được huấn luyện dựa trên nhiều mẫu con khác nhau và kết quả dự đoán sẽ được bầu cử (voting) từ toàn bộ những cây quyết định. Điều này giúp cho mô hình khắc phục được hiện tượng overfiting.

Đối với mô hình này, chọn random_state = 42 nhằm mục đích đảm bảo rằng mọi lần chạy mã sẽ tạo ra cùng một rừng ngẫu nhiên với cùng các cây, giúp hệ thống có thể so sánh và tái lập lại kết quả một cách nhất quán.

2.1.5. Huấn luyện và đánh giá mô hình

Sau khi cây quyết định đã được xây dựng, nó cần được huấn luyện trên dữ liệu huấn luyện. Dữ liệu huấn luyện thường chứa các sự kiện đã được gán nhãn là "bình thường" hoặc "xâm nhập." Sau đó, mô hình cây quyết định sẽ học từ dữ liệu này và có khả năng phân loại các sự kiện mới.

Để đánh giá mô hình, có thể sử dụng các phương pháp như crossvalidation hoặc chia dữ liệu thành tập huấn luyện và tập kiểm tra. Đánh giá mô hình bằng cách sử dụng các metric như precision, recall, và F1-score để đảm bảo rằng mô hình hoạt động tốt trên dữ liệu thực tế.

2.2. Các bộ dữ liệu

2.2.1. Bộ dữ liệu KDD cup 1999

2.2.1.1. Mô tả chung

Dataset KDD Cup 1999 là một phiên bản của bộ dữ liệu DARPA 1998, được sử dụng trong cuộc thi "Các công cụ khai phá dữ liệu và nghiên cứu tri thức quốc tế lần thứ 3 (The Third International Knowledge Discovery and Data Mining Tools Competition)". Nhiệm vụ của cuộc thi là xây dựng một trình phát hiện xâm nhập mạng, một mô hình dự đoán có khả năng phân biệt giữa các kết nối xấu, được gọi là xâm nhập hoặc tấn công, và các kết nối bình thường, tốt. Cơ sở dữ liệu này chứa một bộ dữ liệu tiêu chuẩn cần được kiểm tra, bao gồm nhiều loại xâm nhập được mô phỏng trong môi trường mạng quân sự.

Mục tiêu của bộ dữ liệu: là xây dựng một mô hình dự đoán (tức là một bộ phân loại) có khả năng phân biệt giữa các kết nối "xấu", được gọi là xâm nhập hoặc tấn công, và các kết nối thông thường "tốt".

Tính chất kỹ thuật: Bộ dữ liệu này chứa các bản ghi đã được dán nhãn (tấn công/không phải tấn công). Tổng số các bản ghi là 4.898.431 (trong đó có 3.925.650 bản ghi tấn công và 972.781 bản ghi không phải dạng tấn công), mỗi bản ghi có 41 thuộc tính, dung lượng mỗi bản ghi là 100 byte.

Bảng 2.1. Các dạng tấn công chính trong bộ dữ liệu KDD cup 1999

Dạng	Tên
Dos	Từ chối dịch vụ
R2L	Truy cập trái phép từ xa
U2R	Truy cập trái phép vào quyền root máy nạn nhân
PROBE	Dò quét thông tin
NORMAL	KHÔNG PHẢI DẠNG TẤN CÔNG

2.2.1.2. Tính năng

Có một số loại tính năng dẫn xuất:

Tính năng "same host"chỉ kiểm tra các kết nối trong hai giây qua có cùng máy chủ đích với kết nối hiện tại và tính toán số liệu thống kê liên quan đến hành vi giao thức, dịch vụ, v.v…

Các tính năng "same service" tương tự chỉ kiểm tra các kết nối trong hai giây qua có cùng dịch vụ với kết nối hiện tại.

Các tính năng “same host” và “same service” được gọi chung là các tính năng lưu lượng truy cập dựa trên thời gian của các bản ghi kết nối. Danh sách đầy đủ bộ tính năng được xác định cho bản ghi kết nối được đưa ra trong ba bảng bên dưới.

Bảng 2.2. Các tính năng cơ bản của từng kết nối TCP

Tên tính năng	Mô tả	Kiểu
duration	Độ dài (số giây) của kết nối	continuous
protocol_type	Loại giao thức, ví dụ: tcp, udp, …	discrete
service	Dịch vụ mạng ở đích, ví dụ http,telnet,…	discrete
src_bytes	Số byte dữ liệu từ nguồn đến đích	continuous
dst_bytes	Số byte dữ liệu từ đích đến nguồn	continuous
flag	Trạng thái kết nối bình thường hoặc lỗi	discrete
land	1 nếu kết nối từ/đến cùng một máy chủ/cổng; 0 nếu không	discrete
wrong_fragment	Số mảnh “wrong”	continuous
urgent	Số lượng gói khẩn cấp	continuous

Bảng 2.3. Các tính năng nội dung trong kết nối được đề xuất bởi kiến thức miền

Tên tính năng	Mô tả	Kiểu
hot	số chỉ số “hot”	continuous
num_failed_logins	số lần đăng nhập thất bại	continuous
logged_in	1 nếu đăng nhập thành công; 0 nếu không	discrete
num_compromised	số điều kiện “compromised ”	continuous
root_shell	1 nếu lấy được shell gốc; 0 nếu không	discrete
su_attempted	1 nếu lệnh "su root" được thử; 0 nếu không	discrete

num_root	số lượng truy cập "root"	continuous
num_file_creations	số thao tác tạo tập tin	continuous
num_shells	số lượng lời nhắc shell	continuous
num_access_files	số lượng thao tác trên các tập tin kiểm soát truy cập	continuous
num_outbound_cmds	số lượng lệnh gửi đi trong một phiên ftp	continuous
is hot login	1 nếu thông tin đăng nhập thuộc danh sách "hot"; 0 nếu không	discrete
is_guest_login	1 nếu thông tin đăng nhập là " guest "đăng nhập; 0 nếu không	discrete

Bảng 2.4. Các đặc điểm giao thức được tính toán bằng cửa sổ thời gian hai giây

Tên tính năng	Mô tả	Kiểu
count	số lượng kết nối đến cùng một máy chủ với kết nối hiện tại trong hai giây qua	continuous
	Lưu ý: Các tính năng sau đề cập đến các kết nối cùng máy chủ này.	
serror_rate	% kết nối có lỗi "SYN"	continuous
rerror_rate	% kết nối có lỗi "REJ"	continuous
same_srv_rate	% kết nối đến cùng một dịch vụ	continuous
diff_srv_rate	% kết nối đến các dịch vụ khác nhau	continuous
srv_count	số lượng kết nối đến cùng một dịch vụ với kết nối hiện tại trong hai giây qua	continuous

	Lưu ý: Các tính năng sau đề cập đến các kết nối cùng dịch vụ này.	
srv_serror_rate	% kết nối có lỗi "SYN"	continuous
srv_rerror_rate	% kết nối có lỗi “REJ”	continuous
srv_diff_host_rate	% kết nối đến các máy chủ khác nhau	continuous

2.2.2. Bộ dữ liệu NSL-KDD

2.2.2.1. Mô tả chung

Bộ dữ liệu NSL-KDD (NSL - Knowledge Discovery in Databases) là một tập dữ liệu quan trọng trong lĩnh vực phát hiện xâm nhập mạng (network intrusion detection). Bộ dữ liệu này được tạo ra để nghiên cứu, phát triển và đánh giá các thuật toán và mô hình phát hiện xâm nhập trong môi trường mạng máy tính. NSL-KDD là phiên bản cải tiến của bộ dữ liệu KDD Cup 1999, nhằm loại bỏ một số vấn đề liên quan đến cân bằng dữ liệu và trùng lặp trong dữ liệu gốc.

Mục tiêu của bộ dữ liệu:Mục tiêu chính của NSL-KDD là cung cấp một bộ dữ liệu chuẩn để nghiên cứu và phát triển các thuật toán và mô hình phát hiện xâm nhập trong mạng máy tính.

Cấu trúc và tính chất của dữ liệu: Bộ dữ liệu bao gồm một tập các kết nối mạng (network connections), trong đó mỗi kết nối được gắn nhãn (label) để phân biệt giữa các kết nối bình thường và các kết nối có khả năng là tấn công hoặc xâm nhập.

Tính chất kỹ thuật: Bộ dữ liệu NSL-KDD bao gồm nhiều cột mô tả chi tiết về mỗi kết nối, bao gồm thông tin về thời gian, giao thức, dịch vụ, trạng thái, số byte truyền và nhiều đặc trưng khác để mô tả các tình huống mạng. Bộ dữ liệu NSL-KDD cung cấp một tài liệu tham khảo quan trọng cho cộng đồng nghiên cứu về phát hiện xâm nhập và bảo mật mạng máy tính.

2.2.2.2. Phân loại

Bộ dữ liệu NSL-KDD phân loại các kết nối mạng thành nhiều loại chính dựa trên tính chất và mục đích của chúng. Dưới đây là phần phân loại chi tiết của bộ dữ liệu NSL-KDD:

Bảng 2.5. Các dạng tấn công chính trong bộ dữ liệu NSL-KDD

Dạng	Tên
Dos	Từ chối dịch vụ
R2L	Truy cập trái phép từ xa
U2R	Truy cập trái phép vào quyền root máy nạn nhân
PROBE	Dò quét thông tin
NORMAL	KHÔNG PHẢI DẠNG TẤN CÔNG

Bằng cách phân loại kết nối mạng thành các loại trên, bộ dữ liệu NSL-KDD cho phép nghiên cứu và phát triển các mô hình và thuật toán phát hiện xâm nhập mạng để xác định các cuộc tấn công và bảo vệ hệ thống khỏi chúng.

2.2.2.3. Mô tả từng cột

Bộ dữ liệu NSL-KDD bao gồm nhiều cột để mô tả chi tiết về mỗi kết nối mạng. Dưới đây là mô tả một số cột chính trong bộ dữ liệu NSL-KDD:

Duration (Thời gian): Đây là thời gian kéo dài của kết nối trong giây. Cột này cho biết khoảng thời gian mà kết nối được duy trì từ khi bắt đầu đến khi kết thúc.

Protocol_type (Loại giao thức): Cột này chỉ loại giao thức mạng được sử dụng trong kết nối, ví dụ: TCP, UDP, ICMP.

Service (Dịch vụ): Đây là dịch vụ hoặc ứng dụng mà kết nối đang sử dụng. Ví dụ về dịch vụ bao gồm http (truy cập web), smtp (gửi email) và nhiều dịch vụ khác.

Flag (Trạng thái): Cột này mô tả trạng thái của kết nối, ví dụ: FIN (kết thúc kết nối), SYN (bắt đầu kết nối), RST (thiết lập lại kết nối).

Src_bytes (Số byte nguồn): Đây là số lượng byte dữ liệu được gửi từ nguồn (nguồn IP) đến đích (đích IP) trong kết nối.

Dst_bytes (Số byte đích): Số lượng byte dữ liệu được gửi từ đích đến nguồn trong khi kết nối.

Land (Chuyển tiếp trong mạng): Cột này có giá trị 1 nếu nguồn và đích của kết nối là cùng một máy tính, và có giá trị 0 nếu không phải. Nó chỉ ra việc truyền thông xảy ra trong cùng một máy tính hay không.

Wrong_fragment (Fragment sai): Số lượng fragment bị gửi sai hoặc không hợp lệ trong kết nối.

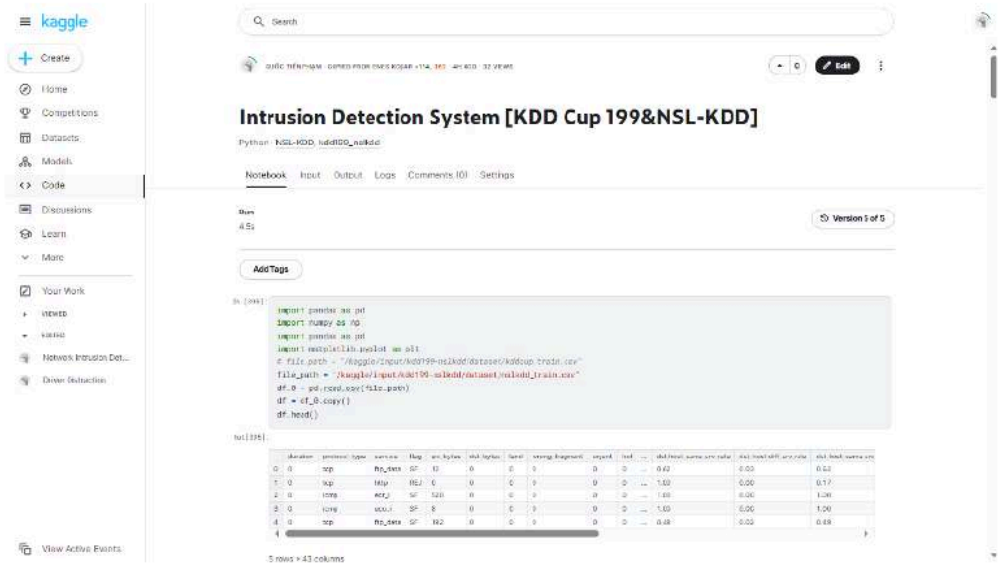
Các cột này cung cấp thông tin quan trọng về các kết nối mạng và được sử dụng để phân loại kết nối thành các loại tấn công hoặc kết nối bình thường trong bộ dữ liệu NSL-KDD. Điều này giúp trong việc phát hiện và phân biệt giữa các cuộc tấn công và hoạt động bình thường trên mạng máy tính.

CHƯƠNG 3. KẾT QUẢ ĐẠT ĐƯỢC

3.1. Xây dựng chương trình

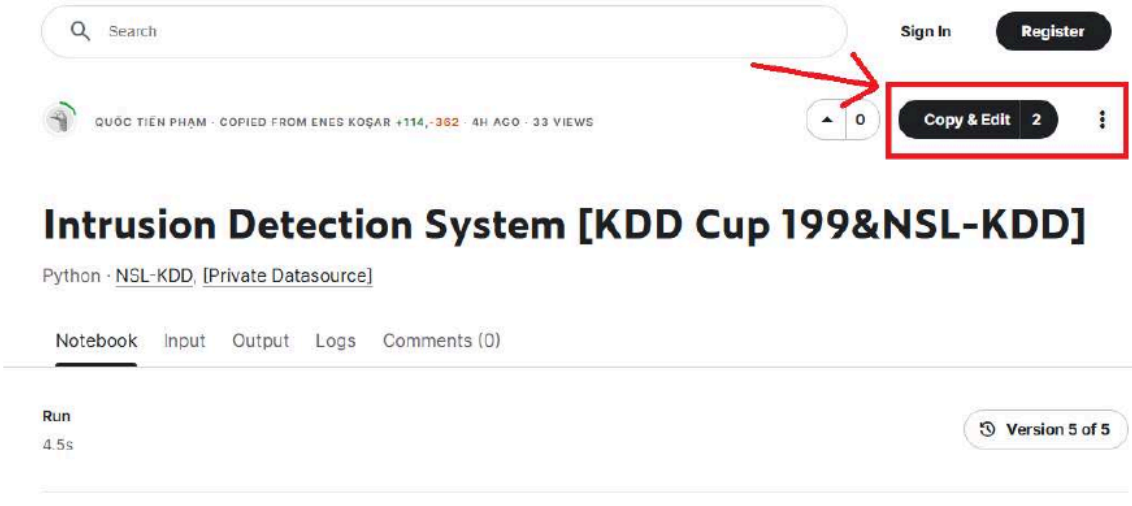
Nhóm đã thực hiện xây dựng được chương trình trên cả python và kaggle, qua thực nghiệm kaggle đưa ra kết quả nhanh hơn và có cấu trúc dễ hiểu hơn nên nhóm xin phép trình bày giao diện thực hiện chương trình trên kaggle.

Đầu tiên truy cập vào đường link: kaggle.com/code/quoctienpham/intrusion-detection-system-kdd-cup-199-nsl-kdd.



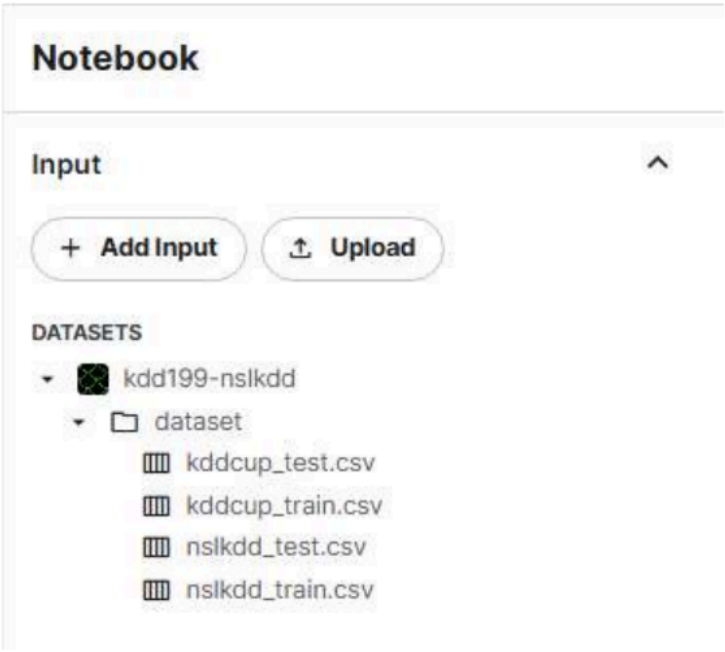
Hình 3.1. Giao diện trang web kaggle

Nhấn chọn Copy & Edit để tạo bản sao chương trình.



Hình 3.2. Tạo bản sao chương trình

Sau khi nhấn tạo bản sao người dùng sẽ được chuyển hướng sang trang kaggle notebook để chạy. Bộ dữ liệu KDD Cup 1999 và NSL-KDD đã được tải lên sẵn.



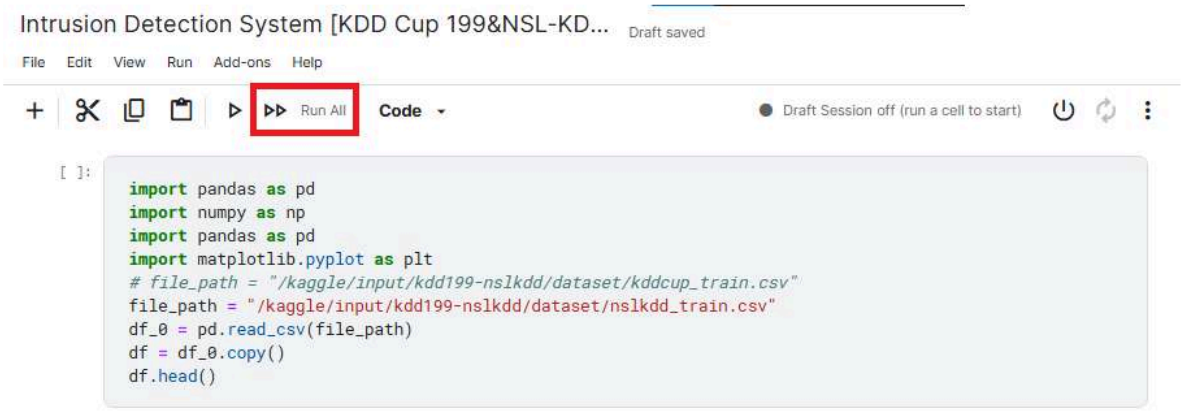
Hình 3.3. Hai bộ dữ liệu KDD Cup 1999 và NSL-KDD đã được tải lên sẵn

Trước khi chạy kiểm tra đường dẫn đến bộ dữ liệu.

```
# file_path = "/kaggle/input/kdd199-nslkdd/dataset/kddcup_train.csv"
file_path = "/kaggle/input/kdd199-nslkdd/dataset/nslkdd_train.csv"
```

Hình 3.4. Kiểm tra đường dẫn đến bộ dữ liệu

Nhấn Run All để thực hiện chạy chương trình với bộ dữ liệu đã chọn. Chương trình sẽ mất một khoảng thời gian để thực hiện chạy và đưa ra kết quả.



Hình 3.5. Chạy chương trình với bộ dữ liệu đã chọn

3.2. Kết quả thực nghiệm

3.2.1. Đánh giá hoạt động của các mô hình

Nhóm lựa chọn đánh giá mô hình dựa trên lớp macro avg thay vì các yếu tố khác vì nó đảm bảo trọng số bằng nhau cho mỗi lớp, không phụ thuộc vào tần suất xuất hiện

của chúng. Điều này đặc biệt quan trọng với tập dữ liệu không cân bằng, nơi một số lớp ít đại diện hơn. Macro avg cho phép đánh giá chính xác hiệu suất của mô hình trên tất cả các lớp, giúp xác định các mô hình hoạt động tốt toàn diện thay vì chỉ tập trung vào các lớp chiếm ưu thế.

Các metric mà nhóm lựa chọn để phân tích là precision, recall và f1-score trong đó: Precision là tỷ lệ mẫu dự đoán đúng là dương tính trên tổng số mẫu được dự đoán là dương tính. Recall là tỷ lệ mẫu dự đoán đúng là dương tính trên tổng số mẫu thực sự là dương tính. F1-score trung bình điều hòa của precision và recall.

3.2.1.1. DecisionTreeClassifier

Với mô hình Decision Tree Classifier, ta chạy 2 lần với 2 bộ dữ liệu là NSL-KDD và KDD được kết quả với các chỉ số là:

Bảng 3.1. Kết quả chạy mô hình Decision Tree Classifier

	precision	recall	f1-score
NSL-KDD	99.42%	99.42%	99.42%
KDD cup 1999	99.96%	99.94%	99.95%

Kết luận từ các chỉ số:

Với bộ dữ liệu NSL-KDD: Mô hình Decision Tree Classifier cho ra kết quả tốt với precision, recall và f1-score đều đạt giá trị khá cao là 99.42%. Điều này cho thấy mô hình hoạt động rất tốt trên bộ dữ liệu này và có khả năng dự đoán chính xác cả positive và negative instances.

Với bộ dữ liệu KDD cup 1999: Precision, recall và F1-score đều khá cao, với giá trị lần lượt là 99.96%, 99.94%, 99.95%. Điều này cho thấy mô hình Decision Tree Classifier cũng hoạt động khá tốt trên bộ dữ liệu này, tuy nhiên, có thể cần điều chỉnh hoặc cải thiện để tăng hiệu suất dự đoán.

Kết luận, với cả 2 bộ dữ liệu NSL-KDD và KDD cup 1999, mô hình Decision Tree Classifier cho thấy độ chính xác và khả năng dự đoán tốt, thể hiện qua các chỉ số trên rất gần với 100%.

3.2.1.2. Multilayer Perceptron Classifier

Với mô hình Multilayer Perceptron Classifier, ta chạy 2 lần với 2 bộ dữ liệu là NSL-KDD và KDD được kết quả với các chỉ số là:

Bảng 3.2. Kết quả chạy mô hình Multilayer Perceptron Classifier

	precision	recall	f1-score
NSL-KDD	97.49%	97.45%	97.46%
KDD cup 1999	99.14%	99.77%	99.46%

Kết luận từ các chỉ số:

Hiệu suất rất cao: Các chỉ số precision, recall, và f1-score đều rất cao, gần như đạt giá trị tối đa. Điều này cho thấy mô hình hoạt động rất tốt trên cả hai bộ dữ liệu, với tỷ lệ dự đoán đúng rất cao.

Kết quả của các metrix khi dự đoán với 2 bộ dữ liệu được cho ra khá tương đồng với nhau, điều này chứng tỏ mô hình có thể làm việc tốt giữa các bộ dữ liệu khác nhau.

3.2.1.3. Logistic Regression

Với mô hình Logistic Regression, ta chạy 2 lần với 2 bộ dữ liệu là NSL-KDD và KDD được kết quả với các chỉ số là:

Bảng 3.3. Kết quả chạy mô hình Logistic Regression

	precision	recall	f1-score
NSL-KDD	93.15%	92.75%	92.84%
KDD cup 1999	97.70%	98.54%	98.11%

Kết luận từ các chỉ số:

Giá trị presision, Recall, F1 – score cao thể hiện hiệu suất phân biệt các nhãn của mô hình khá ấn tượng trên cả 2 bộ dữ liệu.

Kết quả của các metrix khi dự đoán với 2 bộ dữ liệu được cho ra khá tương đồng với nhau, điều này chứng tỏ mô hình có thể làm việc tốt giữa các bộ dữ liệu khác nhau.

3.2.1.4. Random Forest Regression

Với mô hình Random Forest Regression, ta chạy 2 lần với 2 bộ dữ liệu là NSL-KDD và KDD cup 1999 được kết quả với các chỉ số là:

Bảng 3.4. Kết quả chạy mô hình Random Forest Regression

	precision	recall	f1-score
NSL-KDD	99.46%	99.46%	99.46%
KDD cup 1999	99.96%	99.98%	99.97%

Kết luận từ các chỉ số:

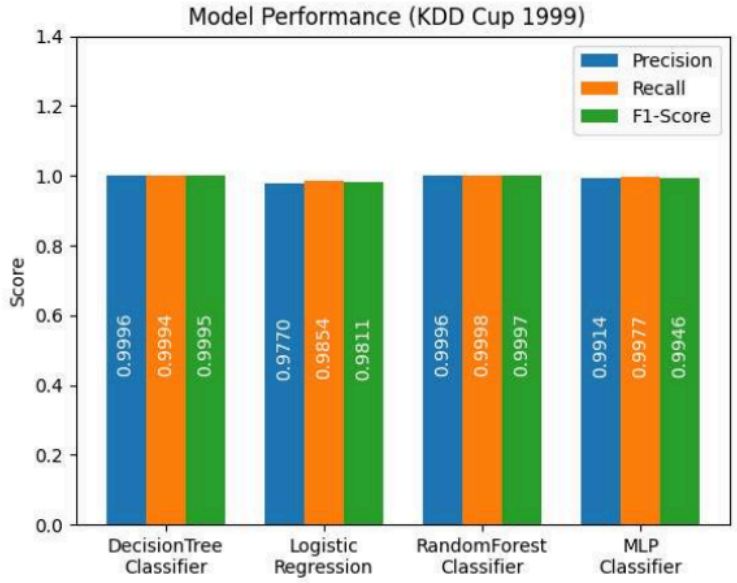
Hiệu suất rất cao: Các chỉ số precision, recall, và f1-score đều rất cao, gần như đạt giá trị tối đa. Điều này cho thấy mô hình hoạt động rất tốt trên cả hai bộ dữ liệu, với tỷ lệ dự đoán đúng rất cao.

Tương đồng giữa hai bộ dữ liệu: Kết quả gần như tương đồng giữa hai bộ dữ liệu KDD cup 1999 và NSL-KDD, cho thấy mô hình có thể xử lý tốt cả hai bộ dữ liệu này.

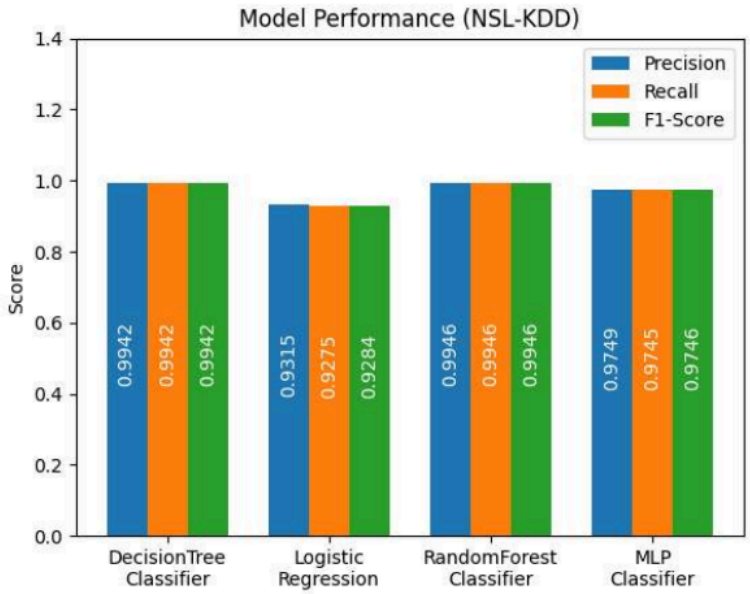
3.2.2. So sánh kết quả với bộ dữ liệu với các model khác nhau

Bảng 3.5. So sánh kết quả các mô hình

	NSL-KDD	KDD Cup 1999
DecisionTreeClassifier	Precision: 99.42% Recall: 99.42% F1 – score: 99.42%	Precision: 99.96% Recall: 99.94% F1 – score: 99.95%
Multilayer Perceptron Classifier	Precision: 97.49% Recall: 97.45% F1 – score: 97.46%	Precision: 99.14% Recall: 99.77% F1 – score: 99.46%
Logistic Regression	Precision: 93.15% Recall: 92.75% F1 – score: 92.84%	Precision: 97.70% Recall: 98.54% F1 – score: 98.11%
Random Forest Regression	Precision: 99.46% Recall: 99.46% F1 – score: 99.46%	Precision: 99.96% Recall: 99.98% F1 – score: 99.97%



Hình 3.6. Kết quả các mô hình khi chạy với bộ dữ liệu KDD Cup 1999



Hình 3.7. Kết quả các mô hình khi chạy với bộ dữ liệu NSL-KDD

Theo kết quả trên, các mô hình MLP Classifier, Decision Tree Classifier, Random Forest Regression và Logistic Regression đều có f1-score cao, trên 92%, nghĩa là các mô hình này đều có khả năng dự đoán đúng các trường hợp thực sự là tấn công cao. Tuy nhiên, mô hình Random Forest Regression có f1-score cao nhất là 99.97% trên bộ KDD cup 1999 và 99.46% trên NSL-KDD, cao hơn các mô hình khác. Mô hình Logistic Regression có f1-score thấp nhất là 92.84% trên bộ NSL-KDD và 98.11% trên KDD

cup 1999. Từ đó cũng có thể thấy mô hình Logistic Regression không thực sự phù hợp với bộ dữ liệu NSL-KDD do có f1-score thấp nhất với 92.84%.

3.2.3. Kết luận

Căn cứ vào f1-score, có thể thấy mô hình Random Forest Regression phù hợp nhất để phân loại các trường hợp thực sự là tấn công.

Có một số lý do khiến một mô hình có thể cho hiệu suất tốt hơn những mô hình khác. Một số lý do phổ biến bao gồm:

- Tính chất của dữ liệu. Một số mô hình có thể phù hợp hơn với một số loại dữ liệu nhất định. Ví dụ, mô hình Random Forest Regression thường phù hợp với dữ liệu có mối quan hệ phức tạp, trong khi mô hình Logistic Regression thường phù hợp với dữ liệu có mối quan hệ tuyến tính.
- Chất lượng của dữ liệu huấn luyện. Dữ liệu huấn luyện càng nhiều và càng đa dạng thì mô hình càng có khả năng dự đoán chính xác.
- Tham số của mô hình. Các tham số của mô hình có thể được tối ưu hóa để cải thiện hiệu suất mô hình.

Trong trường hợp này, mô hình Random Forest Regression cho hiệu suất tốt hơn những mô hình khác có thể là do một hoặc nhiều lý do sau:

- Dữ liệu huấn luyện của mô hình Random Forest Regression có thể phù hợp hơn với các bộ dữ liệu KDD Cup 1999, NSL-KDD. Các bộ dữ liệu này đều bao gồm các trường hợp tấn công mạng với các mối quan hệ phức tạp, trong đó mô hình Random Forest Regression có thể phát huy thế mạnh.
- Dữ liệu huấn luyện của mô hình Random Forest Regression có thể có chất lượng tốt hơn. Dữ liệu huấn luyện có thể có nhiều trường hợp tấn công mạng và các trường hợp không phải là tấn công mạng với tỷ lệ cân bằng, giúp mô hình học được các đặc trưng quan trọng để phân biệt giữa các lớp.
- Các tham số của mô hình Random Forest Regression có thể được tối ưu hóa tốt hơn. Các tham số của mô hình Random Forest Regression có thể được tối ưu hóa để cải thiện hiệu suất mô hình trên các bộ dữ liệu cụ thể.

3.2.4. Hướng phát triển

Trong quá trình phát triển của hệ thống phát hiện xâm nhập mạng, nhóm đã nhận thấy nhiều cơ hội cải tiến và mở rộng. Các hướng phát triển cụ thể bao gồm:

Mở rộng dữ liệu huấn luyện: Sử dụng các bộ dữ liệu phong phú và đa dạng hơn để cải thiện khả năng dự đoán và độ chính xác của mô hình. Việc cập nhật và làm giàu dữ liệu huấn luyện từ các nguồn thực tế sẽ giúp mô hình có khả năng nhận diện tốt hơn các kiểu tấn công mới.

Tối ưu hóa hyperparameters: Áp dụng các kỹ thuật tối ưu hóa hyperparameters như Grid Search hoặc Random Search để tìm ra các tham số tốt nhất cho mô hình, từ đó nâng cao hiệu suất của hệ thống.

Sử dụng các mô hình tiên tiến hơn: Khám phá và áp dụng các mô hình học máy mới và mạnh mẽ hơn như Deep Learning, Neural Networks, hay Ensemble Methods để cải thiện khả năng phát hiện và phân loại xâm nhập.

Thử nghiệm trên môi trường thực tế: Áp dụng mô hình vào các hệ thống mạng thực tế để đánh giá hiệu quả và khả năng thích ứng. Từ đó, thu thập phản hồi và cải thiện hệ thống dựa trên các tình huống thực tế.

Tăng cường bảo mật: Áp dụng các biện pháp bảo mật để bảo vệ hệ thống phát hiện xâm nhập và dữ liệu khỏi các mối đe dọa và tấn công. Đảm bảo rằng hệ thống luôn ở trong trạng thái an toàn và đáng tin cậy.

Phát triển các cơ chế tự động hóa: Xây dựng các quy trình tự động để cập nhật và cải thiện mô hình liên tục, giúp hệ thống luôn thích ứng với các mối đe dọa mới.

Tích hợp vào các hệ thống an ninh mạng hiện có: Đảm bảo hệ thống phát hiện xâm nhập có thể hoạt động cùng với các giải pháp bảo mật khác như Firewall, IDS/IPS để tạo ra một giải pháp bảo mật toàn diện.

Tiếp tục nghiên cứu: Đầu tư vào nghiên cứu để tìm ra các phương pháp mới và hiệu quả hơn trong việc phát hiện và ngăn chặn các cuộc tấn công mạng. Luôn cập nhật kiến thức và công nghệ mới nhất trong lĩnh vực an ninh mạng và học máy.

TÀI LIỆU THAM KHẢO

[1] Giáo trình trường Đại học Công nghiệp Hà Nội.

[2] Cây quyết định Decision Tree: https://trituenhantao.io/kien-thuc/decision-tree/

[3] Learn Python by W3shcool: https://www.w3schools.com/python/default.asp

[4] Mô hình MLPClassifier:

https://scikitlearn.org/stable/modules/generated/sklearn.neural_network.MLPClassifier.html

[5] Mô hình LogisticRegression:

https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html

[6] Mô hình RandomForestRegressor:

https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestRegressor.html

[7] Mô hình DecisionTreeClassifier:

https://scikit-learn.org/stable/modules/generated/sklearn.neural_network.MLPClassifier.html

[8] Luật Công nghệ thông tin 67/2006/QH11, 2006

[9] Luật an ninh mạng 24/2018/QH14, 2018